

Road Slope and Vehicle Mass estimation

CS116.O11.KHCL - Machine Learning with Python: Final Project

Pham Tram Anh

MSSV: 21520587

21520587@gm.uit.edu.vn

Tóm tắt nội dung—Road Slope and Vehicle Mass Estimation
Task đóng một vai trò quan trọng trong các hệ thống giao thông hiện đại. Report này trình bày hướng tiếp cận của em, chi tiết từng bước thực hiện bao gồm EDA, Feature Engineering, chiến lược chia data, lựa chọn mô hình máy học và evaluation.

I. INTRODUCTION

The Estimation of Road Slope and Vehicle Mass là một thách thức phức tạp trong lĩnh vực kỹ thuật giao thông, liên quan đến những yếu tố quan trọng như hiệu suất nhiên liệu, động cơ và vấn đề an toàn. Để giải quyết task phức tạp này, dự án của em tận dụng sức mạnh của các phương pháp máy học. Cụ thể, em sử dụng **K-Nearest Neighbors Regressor** để ước lượng Road Slope và **Random Forest Classifier** để dự đoán Vehicle Mass. Chúng ta sẽ tập trung vào việc sử dụng các dữ liệu thu thập từ xe để dự đoán cả khối lượng và độ nghiêng của mặt đường mà nó đang di chuyển.

II. DATASET DESCRIPTION

Trong dự án này, bộ dữ liệu bao gồm 11 signals thu được từ một chiếc xe, trong đó 9 signals đầu tiên được sử dụng làm đặc trưng đầu vào, và 2 signals cuối cùng được sử dụng làm output. Đáng chú ý là bộ dữ liệu không có thông tin về mặt thời gian và thứ tự các records đã được xáo trộn. Mỗi record trong bộ dữ liệu đại diện cho một frame riêng biệt, và sự thiếu hụt thông tin về thời gian đòi hỏi một thuật toán có khả năng hoạt động độc lập trên mỗi frame.


Các signals bao gồm các tham số quan trọng như engine speed, vehicle speed, torque-related metrics, clutch và engine operation status, cùng với desired torque hay là torque limit. Điểm lưu ý là khối lượng của xe, chỉ được biểu diễn bằng 2 giá trị là 38 t hoặc 49 t.

III. EXPLORATORY DATA ANALYSIS (EDA)

Trước khi đào sâu vào các mô hình học máy, việc thực hiện Exploratory Data Analysis (EDA) là rất quan trọng để tìm hiểu về đặc trưng của bộ dữ liệu và xác định các patterns hay điểm bất thường có thể xuất hiện.

Data Integrity Check Kiểm tra các missing value. May mắn thay, bộ dữ liệu này hoàn chỉnh, không có giá trị null nào xuất hiện.

Outlier Detection Tạo violin plots cho mỗi đặc trưng (Trừ một số đặc trưng không thay đổi và target) để xác định ngoại lệ có thể xuất hiện.



Hình 1. Violin Plot of Feature Columns

Figure 1 cho thấy sự xuất hiện của nhiều outliers trên nhiều đặc trưng, có thể gây ảnh hưởng tiêu cực đến hiệu suất của các mô hình học máy.



Để làm giảm ảnh hưởng của các outliers này, chúng ta có thể sử dụng **RobustScaler** trong quá trình chuẩn hóa đặc trưng.

Correlation Analysis Table I cung cấp cái nhìn tổng quan về mối quan hệ giữa các biến và làm nổi bật sự tương quan giữa các đặc trưng. Đáng chú ý, **RoadSlope_100ms** có một mối tương quan đáng kể với 2 đặc trưng là **ActMod_trqInr_100ms** và **RngMod_trqCrSmin_100ms**.

	RoadSlope_100ms	Vehicle_Mass
RoadSlope_100ms	1.000000	0.257673
ActMod_trqInr_100ms	0.743515	0.084114
RngMod_trqCrSmin_100ms	0.459027	0.604168
Vehicle_Mass	0.257673	1.000000
Epm_nEng_100ms	0.138132	0.156700
VehV_v_100ms	-0.705378	-0.630015

Bảng I
CORRELATION MATRIX OF FEATURES

Ngoài ra, hệ số tương quan mạnh (-0.63) giữa **VehV_v_100ms** và **RngMod_trqCrSmin_100ms** gợi ý chúng ta về khả năng tạo ra một đặc trưng kết hợp mới để cải thiện hiệu suất của mô hình.



IV. DATA PREPROCESSING

Sau khi xác định ngoại lệ, các mối tương quan và distributions trong bước trước, phần này tập trung vào việc tối ưu hóa bộ dữ liệu.

A. Feature Engineering và Reformatting

- Các đặc trưng không quan trọng và không đổi (**CoVeh_trqAcs_100ms**, **Com_rTSC1VRVCURtdrTq**, **Clth_st**, **CoEng_st**, **Com_rTSC1VRRDTrqReq**) được loại bỏ vì chúng không cung cấp thông tin cần thiết để phân biệt giữa các record.
- '**Vehicle_Mass**' được reformatted thành dạng binary encoding dùng cho classification.

Chúng ta tạo một đặc trưng mới **Combined_VehV_RngMod**, bằng cách kết hợp '**VehV_v**' và '**RngMod_trqCrSmin**' sử dụng công thức 1. Cách kết hợp này dựa trên mối tương quan mạnh -0.63 giữa hai biến này.

$$Combined_VehV_RngMod = \frac{RngMod_trqCrSmin_100ms}{VehV_v_100ms} \quad (1)$$

B. Task-specific Dataset Splitting

Chúng ta bắt đầu quá trình phân chia bộ dữ liệu thành các features và target cho cả task regression và classification, sử dụng cùng một tập features cho cả hai tasks.

Tuy nhiên, em cũng giới thiệu một hướng tiếp cận khác, **MultiTask**. Trong chiến lược này, chúng ta sẽ sử dụng giá trị Vehicle Mass được dự đoán để cải thiện dự đoán Road Slope.

Train-Dev-Test Splitting Bộ dataset được chia thành tập train, dev và test cho cả 2 task regression và classification. Tỷ lệ của mỗi tập này trong bộ dataset như sau:

- training set: 70%
- dev set: 15%
- test set: 15%

C. Feature Scaling

Như chúng ta quan sát (Hình 1) có rất nhiều ngoại lệ trên các đặc trưng khác nhau. Chúng ta sẽ giải quyết vấn đề này bằng cách áp dụng Robust scaling cho các đặc trưng để đảm bảo tính đồng đều của chúng trên các độ đo khác nhau.

Em cũng đã thử nghiệm với các phương pháp scaling khác để đánh giá ảnh hưởng của chúng đối với hiệu suất tổng thể của mô hình. Kết quả đánh giá được trình bày trong Bảng II.

Bảng II
MODEL PERFORMANCE WITH DIFFERENT SCALING METHODS

Scaling Method	Public Sets	Private Sets
RobustScaler	87.50	86.56
StandardScaler	84.75	85.26
MinMaxScaler	83.00	-
MaxAbsScaler	82.80	-
Normalizer	65.83	-
PowerTransformer	85.87	-
QuantileTransformer	85.33	-

V. MODELS SELECTION

Như đã đề cập ở trên, chúng ta sẽ sử dụng 2 mô hình riêng biệt để giải quyết 2 tasks đề ra.

A. Vehicle Mass Classifier Task

Mục tiêu của task này là huấn luyện một mô hình phân loại để phân loại khối lượng của một phương tiện vào hai lớp: 38 t hoặc 49 t.

Random Forest Classifier Một thuật toán ensemble learning hoạt động bằng cách xây dựng nhiều decision trees trong quá trình huấn luyện, Quyết định tại mỗi nút của cây dựa trên giá trị của thuộc tính đã chọn.

- Mỗi decision tree trong rừng được huấn luyện trên một tập con ngẫu nhiên của dữ liệu huấn luyện và đưa ra một dự đoán một cách độc lập.

- Kết quả phân loại cuối cùng được xác định bằng cách tổng hợp các dự đoán từ tất cả các cây.

Ngoài mô hình phân loại Random Forest, em đã thử nghiệm với nhiều classifiers khác nhau trước khi chọn ra mô hình cuối cùng. Quá trình thử nghiệm bao gồm việc đánh giá hiệu suất của các classifiers trong Vehicle Mass Classification task.

Bảng III
G-MEAN SCORES FOR VEHICLE MASS CLASSIFICATION MODELS

Classifier	Public Sets	Private Sets
SVC	0.9959	-
Logistic Regression	0.9748	-
Decision Tree Classification	0.9977	0.9945
Random Forest Classification	0.9988	0.9984


B. Road Slope Regression Task

Trong task này, mục tiêu là dự đoán độ dốc của đường dựa trên các đặc trưng đã cho. Chúng ta sẽ đánh giá hiệu suất của các mô hình được chọn, bao gồm KNN Regressor, để đạt được kết quả dự đoán có tính chính xác cao.

KNN Regressor Dự đoán output bằng cách xem xét giá trị trung bình hoặc giá trị trung bình có trọng số của k điểm dữ liệu gần nhất trong không gian đặc trưng.

Việc lựa chọn siêu tham số $n_neighbors$ trong KNN Regressor là cực kỳ quan trọng, vì nó xác định số lượng neighbors đóng góp vào dự đoán. Tham số này cần được điều chỉnh cẩn thận để đạt được hiệu suất tối ưu.


Figure 2 trình bày kết quả thử nghiệm với các giá trị khác nhau của $n_neighbors$ và $leaf_size$.



Hình 2. Regression Performance vs. Number of Neighbors (K) and Leaf Size

Ngoài KNN Regressor, ta cũng sẽ đánh giá nhiều mô hình hồi quy khác, từ các mô hình cơ bản như SVR và Bagging đến các kỹ thuật phức tạp hơn như Gradient Boosting và XGBoost.

Trong số các mô hình hồi quy, Gradient Boosting, AdaBoost và K-Nearest Neighbors (KNN) thể hiện rất tích cực trên cả tập dev và tập test. Gradient Boosting và AdaBoost liên tục đạt được điểm số tích cực, cho thấy khả năng generalization mạnh mẽ.



Hình 3. Comparison of Models Performance on Dev and Test Sets

Tuy nhiên, trong tập private, KNN ($n_neighbors = 1$) với các tham số đã được tune vượt trội so với các 2 thuật toán Boosting.

VI. EVALUATION

Cuối cùng, chúng ta sẽ đánh giá hiệu suất của hai mô hình đã chọn, **Random Forest Classifier** và **KNN Regressor**, trên cả bộ dữ liệu public và private.

	Public Set		Private Set
	Dev	Test	
Classification Task	0.999	1.000	0.998
Regression Task	0.754	0.776	0.794
Overall Score	0.840	0.854	0.865

Bảng IV
PERFORMANCE SCORES ON PUBLIC AND PRIVATE SETS

$$OverallScore = 0.35 \times classification + 0.65 \times regression$$

Note: Hiệu suất classification được đánh giá bằng G-mean score, còn regression score được xác định bởi đề bài.